PROYECTO INTEGRADOR · PRIMER PARCIAL · TÓPICOS Y PROGRAMACIÓN AVANZADA

Detector de Noticias Falsas en Español

NLP + Regresión Logística / Naive Bayes · FastAPI · React

Brayan Albaro Garcia Taboada · Jairo Vargas Figueroa

github.com/jairovargasfigueroa/analisis-sentimiento-resenas

Tag `entrega-final`

¿Esta noticia parece falsa?

- Circulan noticias falsas en español por medios digitales, Facebook y WhatsApp.
- Verificar cada una a mano es lento.
- Objetivo: una **primera señal rápida**: falsa o verdadera, con su probabilidad.
- Y mostrar **cómo** se procesó el texto, paso a paso.

El modelo **no verifica hechos**: juzga cómo está escrito el texto.

The Spanish Fake News Corpus

CC BY 4.0 · etiquetado a mano · Posadas-Durán et al. (2019) y FakeDeS, IberLEF 2021

	PERÍODO	NOTICIAS	VERDADERAS / FALSAS
v1	2018	971	491 / 480
v2 (FakeDeS 2021)	2020–21	572	286 / 286

- 1.542 noticias después de quitar 1 duplicado: **balanceado**, sin `class_weight`.
- Split estratificado 80/20 con `SEED = 42` → 1.233 de entrenamiento / 309 de prueba.
- La **fuente no entra al modelo**: hay sitios satíricos que solo publican falsas.

Las dos versiones no tienen el mismo formato

- La v1 repite el titular dentro del cuerpo (943 de 971).
- La v1 anonimiza cifras y enlaces (`*NUMBER*`, `*URL*`); la v2 trae los reales.
- Sin igualarlo, el modelo aprende **de qué año es** la noticia, no si es falsa.

Corregirlo bajó el F1 del modelo base de 0,796 a **0,786**: ese punto no venía del contenido.

Un solo Pipeline, igual al entrenar y al predecir

```
normalizar → tokenizar → stop words → lematizar → quitar tildes → TF-IDF → modelo
```

¡¡ALERTA!! La OMS confirmó que 3 niños murieron 😱 https://…

→ **exclamacion alerta exclamacion oms confirmar num niño morir emoji**

- Exclamaciones y emojis se vuelven **tokens**: el tono sensacionalista es señal.
- Se **conservan las negaciones**: «no hay vacuna» ≠ «hay vacuna».
- Se serializa entero (`.joblib`): la API no reimplementa el preprocesamiento.

Las tildes se quitan al final

PALABRA	LEMA (SPACY)
afirmó	**afirmar** ✓
afirmo (sin tilde)	**afirmoir** ✗

- spaCy necesita las tildes → se lematiza **antes** de quitarlas.
- Snowball (stemming) une palabras distintas: «murieron» y «muro» → `mur`.
- Lema y stem se comparan con validación cruzada en el experimento E1 (diapositiva 9).

Pestaña Analizar

1. Cabecera con **punto verde**: API y modelo listos (`GET /health`).
2. Botón de ejemplo «Falsa 2021» → **Parece falsa** con su probabilidad.
3. El **paso a paso**: stop words tachadas, lemas y la entrada a TF-IDF.
4. Menos de 20 palabras → `TEXTO_DEMASIADO_CORTO`.
5. Pestaña **Lote**: subir `ejemplo_lote.csv` → 6 noticias con su resumen.

Pasa a Jairo: pestaña Métricas.

La fuente casi decide la etiqueta

14

de 347 fuentes publican de las dos clases

96 %

de las falsas vienen de sitios que nunca publican una verdadera

26 / 0

«bbc» en verdaderas / falsas: la firma se cuela en el texto

- Sitios satíricos: *El Dizque* (143), *El Ruinaversal* (94).
- La fuente **no entra al modelo**: acertaría sin leer el texto.
- Las firmas de agencia (`bbc, afp, efe, reuters, notimex`) van como stop words: el F1 de CV no cambia (0,7631 → 0,7623).

Dos modelos, elegidos con validación cruzada

MODELO	F1 VALIDACIÓN CRUZADA	F1 PRUEBA
Línea base (siempre la mayoritaria)	—	0,336
Regresión Logística (C = 10) ★	**0,766 ± 0,006**	**0,773**
Naive Bayes (alpha = 0,1)	0,695 ± 0,024	0,732

- `GridSearchCV`, 5 particiones estratificadas, **solo con train**.
- Se elige por F1 de validación cruzada; la prueba se mira una sola vez, al final.
- Naive Bayes supone palabras independientes; con bigramas («no», «no creer») no se cumple.

Mismo modelo, cambia una sola cosa

EXPERIMENTO	RESULTADO (F1)	DECISIÓN
E1 · stem vs lema	0,766 vs 0,766	**lema**: igual de preciso, la mitad de variación
E2 · unigramas vs + bigramas	0,760 → 0,766	**bigramas**: «no creer», «año pasado»
E3 · entrenar 2018, probar 2020-21	**0,643**	el COVID no existía en 2018

E3 es un hallazgo, no un fracaso: el modelo aprende una época y habría que reentrenarlo.

Matriz de confusión · Regresión Logística

	PREDICHO FALSA	PREDICHO VERDADERA
REAL FALSA	**116** 75,8 %	**37** 24,2 %
REAL VERDADERA	**33** 21,2 %	**123** 78,8 %

- Errores repartidos (37 y 33): **sin sesgo** hacia una clase.
- Hacia `verdadera`: cifras, días («lunes», «martes»), crónica.
- Hacia `falsa`: «revelar», exclamaciones, «pueblo», «nadie».
- En la app: tabla comparativa, experimentos y errores más seguros.

Falla cuando el estilo engaña

NOTICIA	PREDICCIÓN	POR QUÉ
«Exvicepresidente de Pfizer: no hay necesidad de vacunas»	verdadera 93 %	Falsa con estilo de agencia y cita de autoridad
«Forbes afirma que Angélica Rivera…»	verdadera 90 %	El bulo se apoya en un medio real
«Feministas protestan frente a Palacio Nacional»	falsa 82 %	Palabra de tema que en el corpus abunda en bulos
«Messi: todavía estoy a tiempo de jugar con España»	verdadera 80 %	Sátira escrita como entrevista

Una primera señal, no un verificador

- Supera a la línea base por **44 puntos** de F1 con dos modelos simples y explicables.
- **Aprende cómo está escrita una noticia, no si es verdad.**
- Los datos mandan: la fuente y las firmas filtradas habrían dado un modelo «perfecto» e inútil.
- Se degrada con el tiempo (E3): habría que reentrenarlo con noticias nuevas.
- Reproducible: `python -m src.models.train` da siempre los mismos números (SEED = 42).

Todo sale de `params.yaml`: cambiar una línea y reentrenar con `--rapido` tarda ~45 s.