PROYECTO INTEGRADOR · PRIMER PARCIAL · TÓPICOS Y PROGRAMACIÓN AVANZADA

Detector de Noticias Falsas en Español

NLP + Regresión Logística / Naive Bayes · FastAPI · React

Brayan Albaro Garcia Taboada · Jairo Moises Vargas Figueroa

github.com/jairovargasfigueroa/detector-noticias-falsas

Tag `entrega-final`

¿Esta noticia parece falsa?

- Circulan noticias falsas en español por medios digitales, Facebook y WhatsApp.
- Verificar cada una a mano es lento.
- Objetivo: una **primera señal rápida**: falsa o verdadera, con su probabilidad.
- Y mostrar **cómo** se procesó el texto, paso a paso.

El modelo **no verifica hechos**: juzga cómo está escrito el texto.

The Spanish Fake News Corpus

CC BY 4.0 · etiquetado a mano · Posadas-Durán et al. (2019) y FakeDeS, IberLEF 2021

NOTICIAS POR VERSIÓN Y CLASE



- 1.542 noticias tras quitar 1 duplicado: **balanceado** (777 / 765).
- Split estratificado 80/20, `SEED = 42` → 1.233 / 309.
- La **fuente no entra al modelo**.

LAS DOS VERSIONES NO TIENEN EL MISMO FORMATO

- Encabezados distintos: `Category` / `CATEGORY`, `Topic` / `TOPICS`.
- Etiqueta como texto (`Fake`) en v1 y booleano (`False`) en v2.
- La v1 repite el titular dentro del cuerpo (943 de 971).
- La v1 anonimiza cifras y enlaces (`*NUMBER*`, `*URL*`).

Sin igualarlo, el modelo aprende **de qué año es** la noticia. Corregirlo bajó el F1 base de 0,796 a 0,786: ese punto era falso.

Un solo Pipeline, igual al entrenar y al predecir

```
normalizar → tokenizar → stop words → lematizar → quitar tildes → TF-IDF → modelo
```

```
¡¡ALERTA!! La OMS confirmó que 3 niños murieron 😱 https://…

→ exclamacion alerta exclamacion oms confirmar num niño morir emoji
```

- Exclamaciones y emojis se vuelven **tokens**: el tono sensacionalista es señal.
- Se **conservan las negaciones**: «no hay vacuna» ≠ «hay vacuna».
- Se serializa entero (`.joblib`): la API no reimplementa el preprocesamiento.

Las tildes se quitan al final

PALABRA	LEMA (SPACY)
afirmó	**afirmar** ✓
afirmo (sin tilde)	**afirmoir** ✗

- spaCy necesita las tildes → se lematiza **antes** de quitarlas.
- Snowball (stemming) une palabras distintas: «murieron» y «muro» → `mur`.
- Lema y stem se comparan con validación cruzada en el experimento E1 (diapositiva 8).

Pestañas Analizar y Lote

1. Cabecera con **punto verde**: API y modelo listos (`GET /health`).
2. Botón de ejemplo «Falsa 2021» → **Parece falsa** con su probabilidad.
3. El **paso a paso**: stop words tachadas, lemas y la entrada a TF-IDF.
4. Menos de 20 palabras → `TEXTO_DEMASIADO_CORTO`.
5. Pestaña **Lote**: subir `ejemplo_lote.csv` → 6 noticias con su resumen.

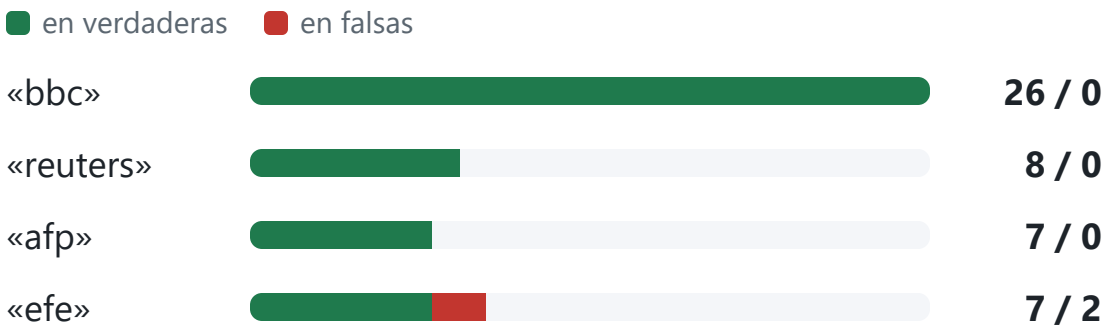
Pasa a Jairo: pestaña Métricas.

La fuente casi decide la etiqueta

¿DE QUÉ FUENTES VIENE CADA CLASE?



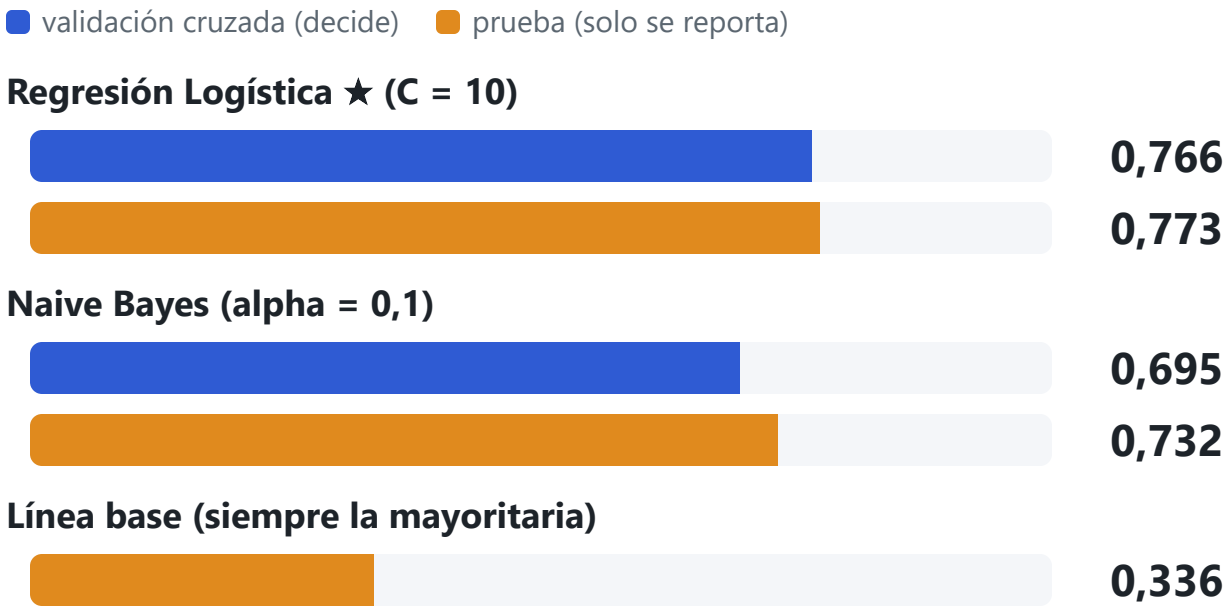
FIRMAS DE AGENCIA DENTRO DEL TEXTO



- De 347 fuentes, solo **14** publican de las dos clases.
- Sitios satíricos: *El Dizque* (143), *El Ruinaversal* (94).
- La fuente **no entra al modelo**: acertaría sin leer el texto.
- Las firmas de agencia van como **stop words**: el F1 de CV no cambia (0,7631 → 0,7623).
- Además: las falsas son más cortas (283 vs 436 palabras) y usan más exclamaciones (15 % vs 9 %).

Dos modelos, elegidos con validación cruzada

F1 MACRO POR MODELO



BÚSQUEDA DE C (REGRESIÓN LOGÍSTICA, CV)



- `GridSearchCV`, 5 particiones, **solo con train**.
- Se elige por CV; la prueba se mira una vez, al final.
- Naive Bayes supone palabras independientes; con bigramas («no», «no creer») no se cumple.

Mismo modelo, cambia una sola cosa

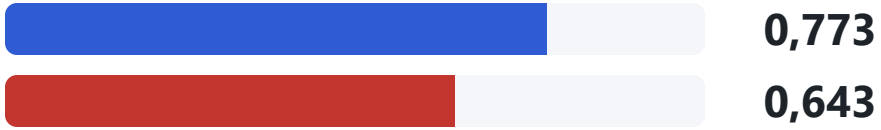
E1 · stem vs lema (F1 CV)



E2 · n-gramas (F1 CV)



E3 · otra época (F1)



- **E1:** empate; queda **lema** porque varía la mitad entre particiones (± 0,006 vs ± 0,015) y sus términos son palabras reales.
- **E2:** los bigramas suman 0,6 puntos: «no creer», «fuente cercano», «año pasado».
- **E3:** entrenar con 2018 y probar con 2020-21 cae a 0,643: el COVID no existía en 2018.

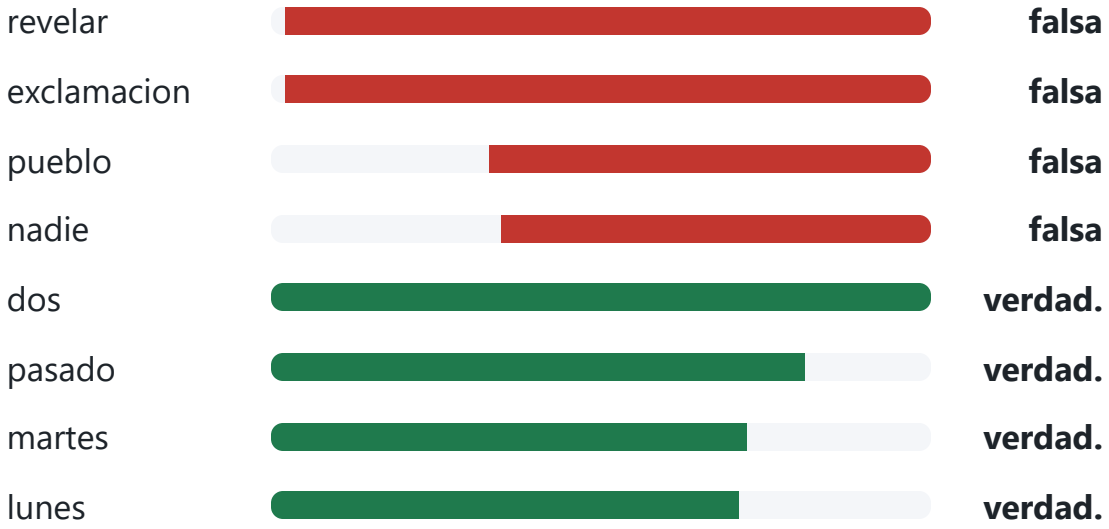
E3 es un hallazgo, no un fracaso: el modelo aprende una época y habría que reentrenarlo.

Matriz de confusión y palabras que pesan

	PREDICHO FALSA	PREDICHO VERDADERA
REAL FALSA	**116** 75,8 %	**37** 24,2 %
REAL VERDADERA	**33** 21,2 %	**123** 78,8 %

Errores repartidos (37 y 33): sin sesgo hacia una clase.

PESO DE CADA TÉRMINO (COEFICIENTE)



Tono y apelación → falsa · cifras y días (lenguaje de agencia) → verdadera.

Falla cuando el estilo engaña

NOTICIA	PREDICCIÓN	POR QUÉ
«Exvicepresidente de Pfizer: no hay necesidad de vacunas»	verdadera 93 %	Falsa con estilo de agencia y cita de autoridad
«Forbes afirma que Angélica Rivera…»	verdadera 90 %	El bulo se apoya en un medio real
«Feministas protestan frente a Palacio Nacional»	falsa 82 %	Palabra de tema que en el corpus abunda en bulos
«Messi: todavía estoy a tiempo de jugar con España»	verdadera 80 %	Sátira escrita como entrevista

Una primera señal, no un verificador

- Supera a la línea base por **44 puntos** de F1 con dos modelos simples y explicables.
- **Aprende cómo está escrita una noticia, no si es verdad.**
- Los datos mandan: la fuente y las firmas filtradas habrían dado un modelo «perfecto» e inútil.
- Se degrada con el tiempo (E3): habría que reentrenarlo con noticias nuevas.
- Reproducible: `python -m src.models.train` da siempre los mismos números (SEED = 42).

Todo sale de `params.yaml`: cambiar una línea y reentrenar con `--rapido` tarda ~45 s.